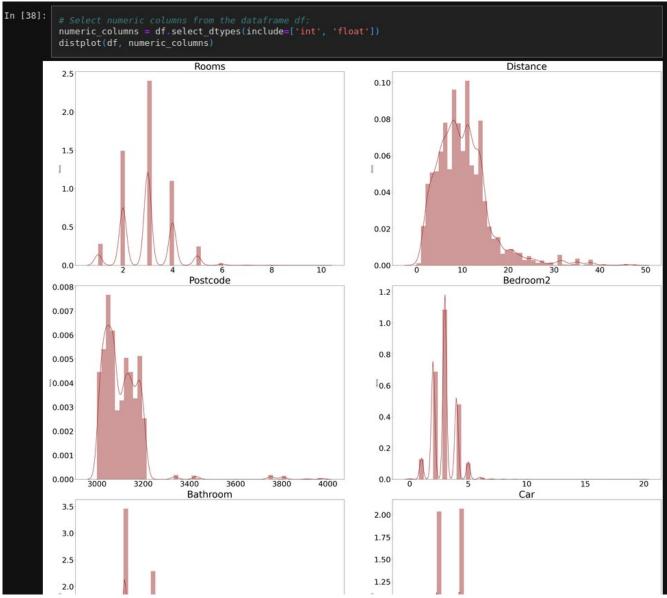
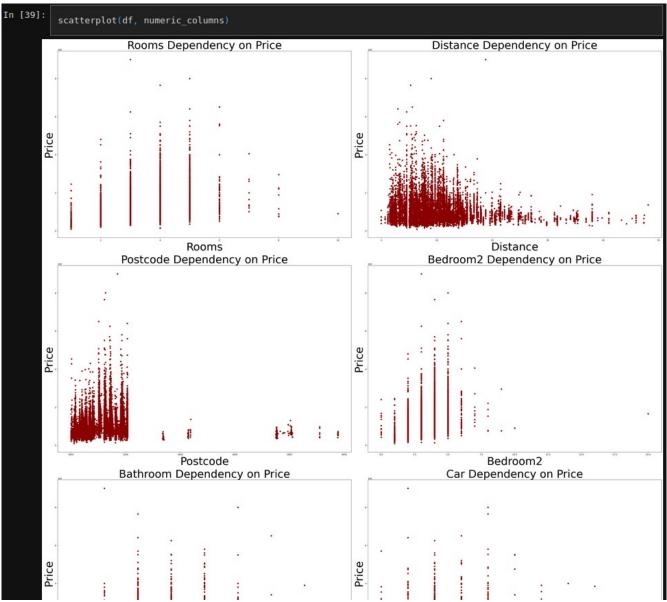
Спочатку я просто зчитав дані з csv файла у датафрейм та вивів його.

In [36]:	# dataset: https://www.kaggle.com/datasets/dansbecker/melbourne-housing-snapshot df = pd.read_csv('./data/melb_data.csv') df.head()															
Out[36]:		Suburb	Address	Rooms	Туре	Price	Method	SellerG	Date	Distance	Postcode		Bathroom	Car	Landsize	Вι
	0	Abbotsford	85 Turner St	2	h	1480000.0	S	Biggin	3/12/2016	2.5	3067.0		1.0	1.0	202.0	
	1	Abbotsford	25 Bloomburg St	2	h	1035000.0	S	Biggin	4/02/2016	2.5	3067.0		1.0	0.0	156.0	
	2	Abbotsford	5 Charles St	3	h	1465000.0	SP	Biggin	4/03/2017	2.5	3067.0		2.0	0.0	134.0	
	3	Abbotsford	40 Federation La	3	h	850000.0	PI	Biggin	4/03/2017	2.5	3067.0		2.0	1.0	94.0	
	4	Abbotsford	55a Park St	4	h	1600000.0	VB	Nelson	4/06/2016	2.5	3067.0		1.0	2.0	120.0	
	5 r	ows × 21 col	umns													

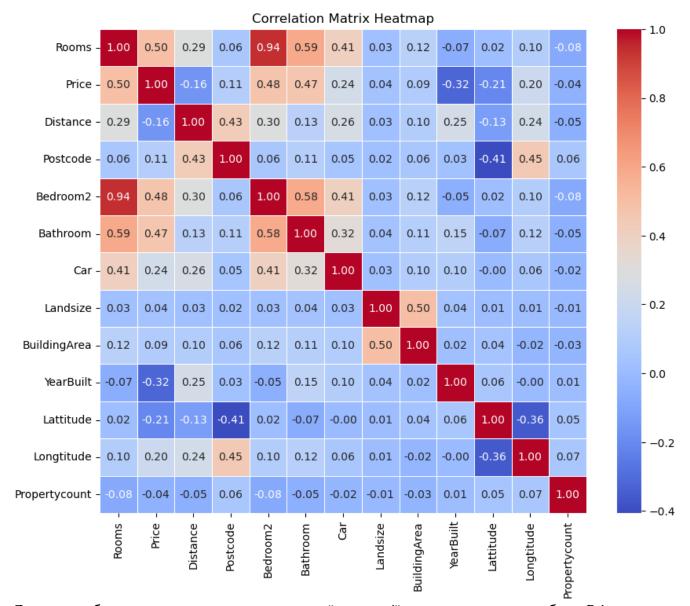
Далі я намалював distplot для усіх числових колонок, щоб подивитися на розподіли, зрозуміти чи потрібно видаляти викиди чині.



А також scatterplot-и, щоб подивитися, як числові стовбчики залежать від таргетної змінної.



Також вивів кореляційну матрицю, щоб мати уявлення про змінні, які корелюють з тергетною змінною



Як можемо бачити, тут немає прямо вираженої кореляції з таргетом, але з стовбцем Price, непогано корелюють такі фічі: Rooms, Bedroom2, Bathroom та YearBuilt. Я вивів інформацію про датафрейм, щоб подивитися чи є в ньому пропущені значення.

```
In [37]:
          df.info()
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 13580 entries, 0 to 13579
       Data columns (total 21 columns):
                           Non-Null Count
            Column
                                            Dtype
                                            object
        0
            Suburb
                           13580 non-null
                           13580 non-null
                                            object
        1
            Address
        2
            Rooms
                           13580 non-null
                                            int64
        3
                           13580 non-null
                                            object
            Type
        4
            Price
                           13580 non-null
                                            float64
        5
                           13580 non-null
            Method
                                            object
        6
            SellerG
                           13580 non-null
                                            object
            Date
                            13580 non-null
                                            object
            Distance
        8
                           13580 non-null float64
        9
            Postcode
                           13580 non-null
                                            float64
            Bedroom2
                           13580 non-null
                                           float64
        10
        11
            Bathroom
                           13580 non-null float64
        12
                           13518 non-null float64
            Car
            Landsize
                           13580 non-null float64
        13
        14
            BuildingArea
                           7130 non-null
                                            float64
        15
            YearBuilt
                           8205 non-null
                                            float64
            CouncilArea
                            12211 non-null
        16
                                            object
        17
            Lattitude
                            13580 non-null
                                            float64
           Longtitude
                           13580 non-null
                                            float64
        18
        19
            Regionname
                           13580 non-null
                                            object
            Propertycount 13580 non-null float64
       dtypes: float64(12), int64(1), object(8)
       memory usage: 2.2+ MB
```

Після цього я заповнюю ці пропущенні значення, в колонці Car, YearBuilt та CouncilArea я заміняю їх на медіани, оскільки це категоріальні колонки, а в колонці BuildingArea заміняю на середнє.

```
In [42]:
           df['Car'].fillna(df['Car'].median(), inplace=True)
           df['BuildingArea'].fillna(df['BuildingArea'].mean(), inplace=True)
          df['YearBuilt'].fillna(df['YearBuilt'].median(), inplace=True)
           df['CouncilArea'].fillna(df['CouncilArea'].value_counts()[0], inplace=True)
          df.info()
        <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 13580 entries, 0 to 13579
        Data columns (total 21 columns):
                             Non-Null Count Dtype
             Column
                             13580 non-null object
         0
             Suburb
         1
             Address
                             13580 non-null object
             Rooms
                            13580 non-null int64
         2
         3
                            13580 non-null object
             Type
             Price
                            13580 non-null float64
         5
             Method
                            13580 non-null object
         6
            SellerG
                            13580 non-null object
                            13580 non-null object
         7
             Date
                            13580 non-null float64
         8
             Distance
                            13580 non-null float64
         9
             Postcode
                            13580 non-null float64
         10 Bedroom2

      11 Bathroom
      13580 non-null float64

      12 Car
      13580 non-null float64

      13 Landsize
      13580 non-null float64

         14 BuildingArea 13580 non-null float64
         15 YearBuilt 13580 non-null float64
         16 CouncilArea
                            13580 non-null object
                             13580 non-null float64
         17 Lattitude
                             13580 non-null float64
         18 Longtitude
         19 Regionname
                             13580 non-null object
         20 Propertycount 13580 non-null float64
        dtypes: float64(12), int64(1), object(8)
        memory usage: 2.2+ MB
```

Після цього я вирішив витягнути фічі з колонки Date(дата продажу будинку у форматі DD/MM/YYYY), а також почистити колонку Address, яка має формат №будику вулиця.

```
In [44]:
# Remove numeric and alphanumeric characters from the 'Address' column using regular expressions
df['Address'] = df['Address'].str.replace(r'[0-9]+[a-zA-Z]*', '', regex=True).str.strip()

# Convert the 'Date' column to a datetime format with the specified format
df['Date'] = pd.to_datetime(df['Date'], format='%d/%m/%Y')

# Extract the year from the 'Date' column and create a new 'Year' column
df['Year'] = df['Date'].dt.year

# Extract the month from the 'Date' column and create a new 'Month' column
df['Month'] = df['Date'].dt.month

# Extract the weekend information from the Date column and create a new 'Is weekend' column
df['Is weekend'] = df['Date'].apply(is_weekend_or_weekday)

# Drop the original 'Date' column from the DataFrame
df = df.drop('Date', axis=1)
```

3 колонки Address я видалив номери будинків, за допомогою регулярного виразу і залишив тільки назви вулиць. А з колонки Date я повитягував рік продажу, місяць продажу, а також чи був проданий будинок у вихідний день чи ні.

Далі я видалив з датафрейму колонки Postcode, Lattitude, Longtitude, Suburb оскільки точність регресії з цими колонками була зовсім погана.

```
In [45]:
# Check if the 'Postcode' column exists in the DataFrame
if 'Postcode' in df.columns:
    # If it exists, drop the 'Postcode' column from the DataFrame
    df.drop('Postcode', axis=l, inplace=True)

# Check if the 'Lattitude' column exists in the DataFrame
if 'Lattitude' in df.columns:
    # If it exists, drop the 'Lattitude' column from the DataFrame
    df.drop('Lattitude', axis=l, inplace=True)

# Check if the 'Longtitude' column exists in the DataFrame
if 'Longtitude' in df.columns:
    # If it exists, drop the 'Longtitude' column from the DataFrame
    df.drop('Longtitude', axis=l, inplace=True)

# Check if the 'Suburb' column exists in the DataFrame
if 'Suburb' in df.columns:
    # If it exists, drop the 'Suburb' column from the DataFrame
    df.drop('Suburb', axis=l, inplace=True)
```

Далі я використав One-Hot для того, щоб закодувати категоріальні стовбці.

c	<pre># Define a list of categorical columns to be one-hot encoded categorical_cols = ['Address', 'Type', 'Method', 'CouncilArea', 'SellerG', 'Regionname', 'YearBuilt', 'Year',</pre>												
# e	# Concatenate the one-hot encoded columns with the original DataFrame, dropping the original categorical columns # This creates a new DataFrame 'encoded_df' with one-hot encoded categorical variables and the remaining numeric encoded_df = pd.concat([df.drop(categorical_cols, axis=1), encoded_df], axis=1).astype(int) encoded_df.head() : Rooms Price Distance Bedroom2 Bathroom Car Landsize BuildingArea Propertycount Abbotsford Month_2 Month_3 Gr												
0	2	1480000	2	2	1		202	151	4019	0	0	ļ	
1	2	1035000	2	2		0	156	79	4019	0		(
2	3	1465000	2	3	2	0	134	150	4019	0	0		
3	3	850000	2	3	2		94	151	4019	0	0		
4	4	1600000	2	3	1	2	120	142	4019	0	0		
5 r	ows × 672	5 columns	5										

Після цього я засплітив дані на навчальну та тестову вибірку.

```
In [48]:
# Split the DataFrame into features (X) and the target variable (y)
X = encoded_df.drop('Price', axis=1)
y = encoded_df['Price']

# Split the data into training and testing sets using train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Ну і після цього я вже треную лінійну регресію, лінійну регресію з L2 регуляризацією(Ridge), а також xgboost.Regressor в основі якого лінійні регресії, а також вимірюю результати кожного методу на навчальній вибірці. Найкращі результати показала лінійна регресія з L2 регуляризацією, але я не зміг виконати GridSearch для xgboost.Regressor оскільки, для цього потрібні обчислювальні ресурси, яких у мене немає.

```
In [49]:
          model = LinearRegression()
          model fit(X train, y train)
          y pred train = model.predict(X train)
          mse_train = mean_squared_error(y_train, y_pred_train)
          r2 train = r2 score(y train, y pred train)
          print(f"Train: R-squared (R^2) Score: {r2_train}")
          print(f"Train: Mean Squared Error (MSE): {mse train}")
          y pred test = model.predict(X test)
          mse test = mean squared error(y test, y pred test)
          r2_test = r2_score(y_test, y_pred_test)
          print(f"Test: R-squared (R^2) Score: {r2_test}")
          print(f"Test: Mean Squared Error (MSE): {mse test}")
        Train: R-squared (R^2) Score: 0.8821540153615146
        Train: Mean Squared Error (MSE): 48499996026.22382
        Test: R-squared (R^2) Score: 0.6137605952202531
        Test: Mean Squared Error (MSE): 153419642558.5499
```

```
In [50]:
           model = Ridge(alpha=4)
          model.fit(X train, y train)
          y pred train = model.predict(X train)
           mse train = mean squared error(y train, y pred train)
           # Calculate the R-squared (R^2) score to assess how well the model fits the data
           r2 train 2 r2 score(y train, y pred train)
          print(f"Train: R-squared (R^2) Score: {r2_train}")
print(f"Train: Mean Squared Error (MSE): {mse_train}")
          y pred test = model.predict(X test)
          mse test = mean squared error(y test, y pred test)
          r2 test = r2 score(y test, y pred test)
           print(f"Test: R-squared (R^2) Score: {r2_test}")
           print(f"Test: Mean Squared Error (MSE): {mse test}")
        Train: R-squared (R^2) Score: 0.7681830543024877
        Train: Mean Squared Error (MSE): 95405210280.44421
        Test: R-squared (R^2) Score: 0.6857348822926175
```

Test: Mean Squared Error (MSE): 124830458598.03333

```
In [51]:
          model = xgb.XGBRegressor(booster='gblinear', eval metric='rmse', reg_lambda=0.1, n_estimators=1000)
          model.fit(X_train, y_train)
          y pred train = model.predict(X train)
          mse_train = mean_squared_error(y_train, y_pred_train)
          r2_train = r2_score(y_train, y_pred_train)
          print(f"Train: R-squared (R^2) Score: {r2_train}")
          print(f"Train: Mean Squared Error (MSE): {mse train}")
          y_pred_test = model.predict(X_test)
          mse test = mean squared_error(y_test, y_pred_test)
          r2_test = r2_score(y_test, y_pred_test)
          print(f"Test: R-squared (R^2) Score: {r2_test}")
          print(f"Test: Mean Squared Error (MSE): {mse test}")
        Train: R-squared (R^2) Score: 0.5922277808718404
        Train: Mean Squared Error (MSE): 167820321311.66556
        Test: R-squared (R^2) Score: 0.6175070037967498
Test: Mean Squared Error (MSE): 151931517169.03354
```

I на останок я натренував кастомну лінійну регресію не на всіх даних, а тільки на частині, оскільки це знову ж таки вимагає обчислювальних ресурсів, яких в мене немає і порівняв результати зі вбудованою регресію. Результати майже однакові, похибка може бути через якісь округлення, які робить вбудована регресія.

Також ось реалізація кастомної лінійної регресії, я просто використав метод найменших квадратів.